Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления»

КАФЕДРА «Системы обработки информации и управления»

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

К КУРСОВОМУ ПРОЕКТУ

НА ТЕМУ:

Решение задачи машинного обучения

Студент группы ИУ5Ц-81Б (Группа)	_____ (Подпись, дата)	Гаранин А.В. (И.О.Фамилия)
Руководитель курсового проекта	_____ _____ (Подпись, дата)	_Гапанюк Ю.Е. (И.О.Фамилия)
Консультант	_____ _____ (Подпись, дата)	_____ (И.О.Фамилия)

Москва, 2020 г.

Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

УТВЕРЖДАЮ
Заведующий кафедрой _____
(Индекс)
_____ _____
(И.О.Фамилия)
« _____ » _____ 20 ____ г.

З А Д А Н И Е
на выполнение курсового проекта

по дисциплине «Технологии машинного обучения»

Студент группы ИУ5Ц-81Б

_____Гаранин Антон Викторович_____
(Фамилия, имя, отчество)

Тема курсового проекта: “Бинарная классификация”
_____
_____

Направленность КП (учебный, исследовательский, практический, производственный, др.)
_____

Источник тематики (кафедра, предприятие, НИР) _____

График выполнения проекта: 25% к 4 нед., 50% к 8 нед., 75% к 12 нед., 100% к 16 нед.

Задание решение задачи машинного обучения на основе материалов дисциплины. Выполняется студентом единолично.
_____
_____
_____

Оформление курсового проекта:

Расчетно-пояснительная записка на __27___ листах формата А4.
Перечень графического (иллюстративного) материала (чертежи, плакаты, слайды и т.п.)
_____
_____
_____

Дата выдачи задания «12 » февраля 2020 г.

Руководитель курсового проекта _____ Гапанюк Ю.Е.
(Подпись, дата) (И.О.Фамилия)

Студент _____ Гаранин А.В.
(Подпись, дата) (И.О.Фамилия)

Примечание: Задание оформляется в двух экземплярах: один выдается студенту, второй хранится на кафедре.

Содержание

1. ВВЕДЕНИЕ

В данном курсовом проекте предстоит выполнить типовую задачу машинного обучения - провести анализ данных, провести некоторые операции с датасетом, подобрать модели, а также подобрать наиболее подходящие гиперпараметры выбранных моделей.

Машинное обучение очень актуально в современном мире, оно используется практически во многих сферах. Программист должен подбирать подходящие технологии машинного обучения для достижения наилучших результатов. Чему мы и научимся в этом курсовом проекте. Попробуем не менее пяти видов различных моделей и подберем наилучшую из них на основе выбранных метрик. Также построим вспомогательные графики, которые помогут нам визуально взглянуть на все необходимые показатели.

2. Выполнение курсового проекта

2.1. Поиск и выбор набора данных для построения моделей машинного обучения. На основе выбранного набора данных студент должен построить модели машинного обучения для решения или задачи классификации, или задачи регрессии.

В качестве набора данных мы будем использовать набор данных по обнаружению сердечного заболевания у пациента.

Файл содержит следующие колонки:

1. age - возраст пациента;
2. sex - пол пациента (1 = мужчина; 0 = женщина);
3. chest pain type (4 values) - тип боли в груди пациента;
4. resting blood pressure - кровяное давление в покое;
5. serum cholestoral in mg/dl - содержание холестирина;
6. fasting blood sugar > 120 mg/dl - уровень сахара в крови натощак;
7. resting electrocardiographic results (values 0,1,2) - результаты электрокардиографии в покое;
8. maximum heart rate achieved - максимальная частота сердечных сокращений;
9. exercise induced angina - стенокардия, вызванная физической нагрузкой;
10. oldpeak = ST depression induced by exercise relative to rest - показание на электрокардиограмме;
11. the slope of the peak exercise ST segment - показание на электрокардиограмме;
12. number of major vessels (0-3) colored by flourosopy - количество крупных сосудов;
13. thal: 3 = normal; 6 = fixed defect; 7 = reversable defect - анализ из крови;
14. target - наличие или отсутствие сердечного заболевания у пациента.

Будем решать задачу классификации. В качестве целевого признака возьмем колонку exercise induced angina. Поскольку она содержит только значения 0 или 1, то это задача бинарной классификации.

```
[1] #Произведем импорт необходимых библиотек:
    import numpy as np
    import pandas as pd
    import seaborn as sns

    import matplotlib.pyplot as plt
    from sklearn.preprocessing import MinMaxScaler
    from sklearn.model_selection import train_test_split
    from sklearn.metrics import roc_auc_score, precision_score, recall_score, accuracy_score, plot_confusion_matrix, roc_curve
    from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier
    from sklearn.model_selection import GridSearchCV
    from sklearn.svm import SVC
    from sklearn.neighbors import KNeighborsClassifier
    from sklearn.tree import DecisionTreeClassifier


    %matplotlib inline

    # Установим тип графиков
    sns.set(style="ticks")

    # Для лучшего качество графиков
    from IPython.display import set_matplotlib_formats
    set_matplotlib_formats("retina")

    # Установим ширину экрана для отчета
    pd.set_option("display.width", 80)
```

```
/usr/local/lib/python3.6/dist-packages/statsmodels/tools/_testing.py:19: FutureWarning: pandas.util.testing is deprecated. Use the functions in the public API at pandas.testing instead.
  import pandas.util.testing as tm
```

2.2. Проведение разведочного анализа данных. Построение графиков, необходимых для понимания структуры данных. Анализ и заполнение пропусков в данных.

Загрузим данные с помощью библиотеки pandas и выведем первые 5 строк:

```
[2] # Загрузим набор данных и выведем её первые пять записей
    data = pd.read_csv('/heart.csv')
    data.head()
```

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
0	63	1	3	145	233	1	0	150	0	2.3	0	0	1	1
1	37	1	2	130	250	0	1	187	0	3.5	0	0	2	1
2	41	0	1	130	204	0	0	172	0	1.4	2	0	2	1
3	56	1	1	120	236	0	1	178	0	0.8	2	0	2	1
4	57	0	0	120	354	0	1	163	1	0.6	2	0	2	1

```
[3] # Вычислим размер датасета
    data.shape
```

```
(303, 14)
```

В итоге, 303 строчки и 14 колонок

```
[4]  # Увидим, из каких колонок состоит датасет
     data.columns
```

```
Index(['age', 'sex', 'cp', 'trestbps', 'chol', 'fbs', 'restecg', 'thalach',
       'exang', 'oldpeak', 'slope', 'ca', 'thal', 'target'],
      dtype='object')
```

```
[5]  # Поймем какими типами данных заполнены колонки
     data.dtypes
```

```
age           int64
sex           int64
cp            int64
trestbps      int64
chol          int64
fbs           int64
restecg       int64
thalach       int64
exang         int64
oldpeak     float64
slope         int64
ca            int64
thal          int64
target        int64
dtype: object
```

```
[6]  # Проверим наличие пустых значений
     data.isnull().sum()
```

```
age         0
sex         0
cp          0
trestbps    0
chol        0
fbs         0
restecg     0
thalach     0
exang       0
oldpeak     0
slope       0
ca          0
thal        0
target      0
dtype: int64
```

Видим, что датасет не содержит пропусков данных.

```
[7] # Убедимся, что целевой признак для задачи бинарной классификации содержит только 0 и 1
    data['exang'].unique()
```

```
array([0, 1])
```

```
[8] # Оценим дисбаланс классов для Heart
    fig, ax = plt.subplots(figsize=(4,4))
    plt.hist(data['exang'])
    plt.show()
```

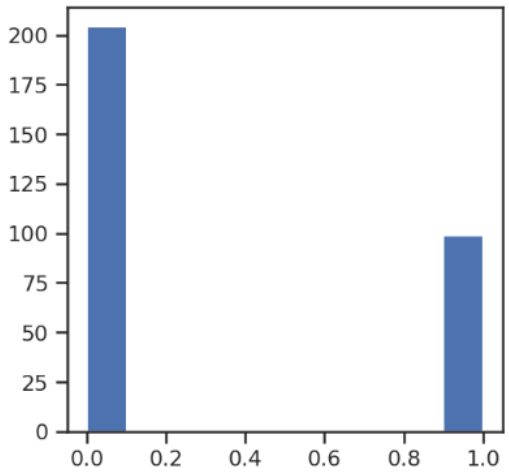

Выясним, сколько значений под «0», а сколько под «1»:

```
[9] data['exang'].value_counts()
```

```
0    204
1     99
Name: exang, dtype: int64
```

```
# посчитаем дисбаланс классов
total = data.shape[0]
class_0, class_1 = data['exang'].value_counts()
print('Класс 0 составляет {}%, а класс 1 составляет {}%.'
      .format(round(class_0 / total, 2)*100, round(class_1 / total, 2)*100))
```

```
Класс 0 составляет 67.0%, а класс 1 составляет 33.0%.
```

Как мы видим, дисбаланс классов практически отсутствует.

```
[11] # Скрипичные диаграммы для некоторых колонок колонок
     for col in ['age', 'sex', 'chol', 'thalach', 'thal']:
         sns.violinplot(x=data[col])
         plt.show()
```

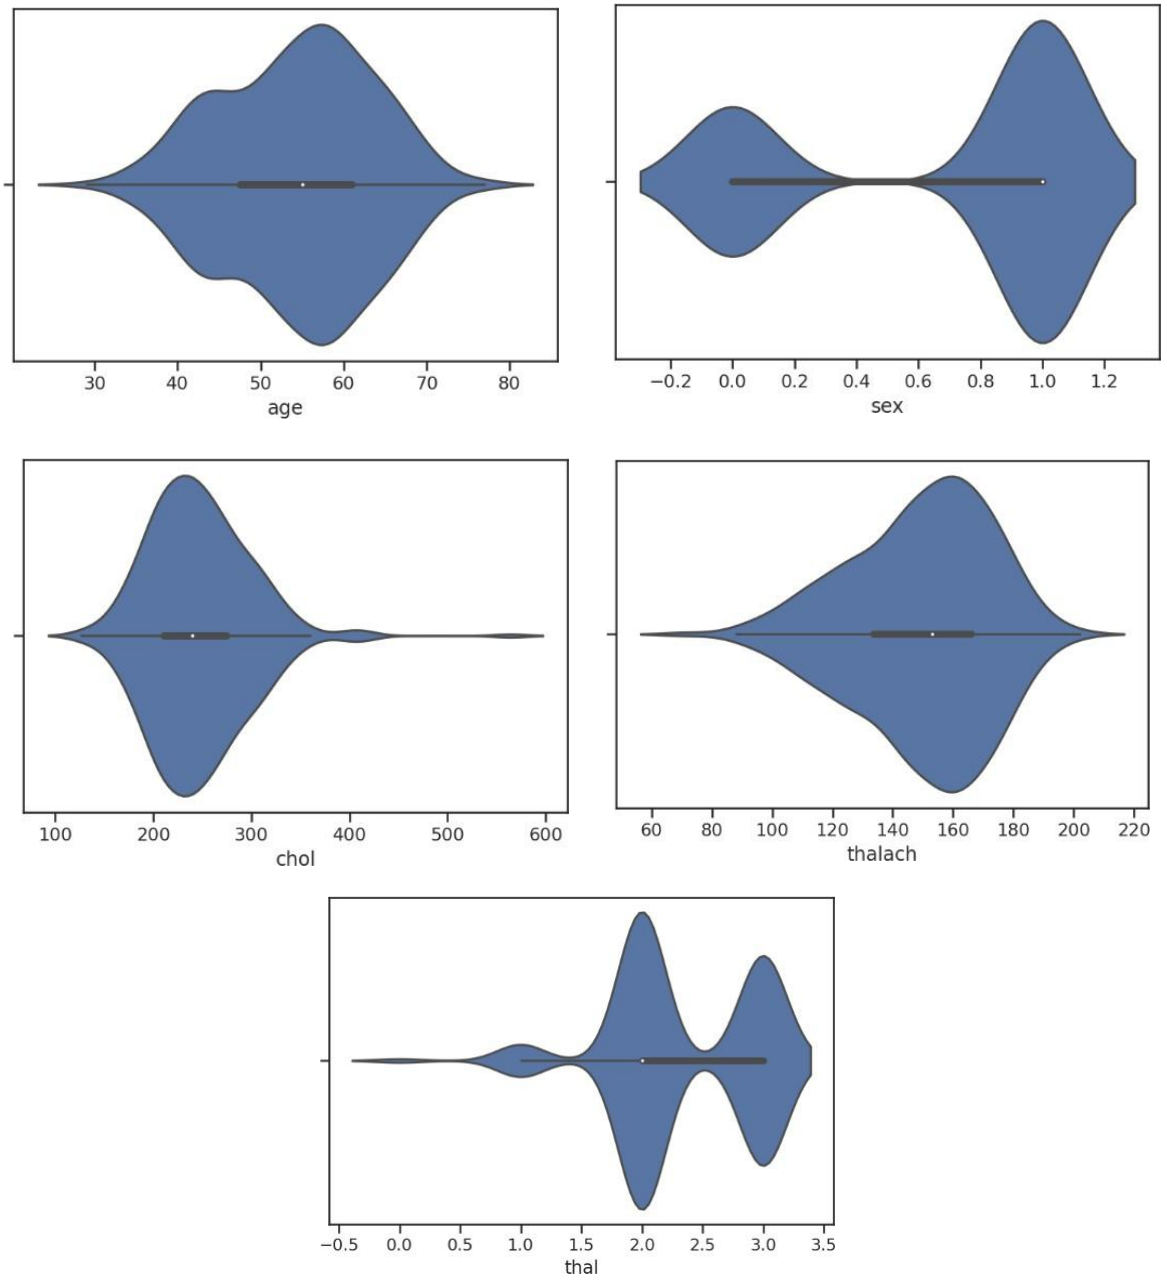

2.3. Выбор признаков, подходящих для построения моделей. Кодирование категориальных признаков. Масштабирование данных. Формирование вспомогательных признаков, улучшающих качествомоделей.

Для построения моделей будем использовать все признаки.

Категориальные признаки отсутствуют, их кодирования не требуется. Исключением является признак exang, но в представленном датасете он уже закодирован на основе подхода LabelEncoding.

Вспомогательные признаки для улучшения качества моделей мы строить не будем.

Выполним масштабирование данных.

```
[12] # Числовые колонки для масштабирования
     scale_cols = ['age', 'sex', 'cp', 'trestbps', 'chol', 'fbs', 'restecg', 'thalach', 'oldpeak', 'slope', 'ca', 'thal', 'target']
```

```
[13] sc = MinMaxScaler()
     sc_data = sc.fit_transform(data[scale_cols])
```

```
[14] # Добавим масштабированные данные в набор данных
     for i in range(len(scale_cols)):
         col = scale_cols[i]
         new_col_name = col + '_scaled'
         data[new_col_name] = sc_data[:,i]
```

```
[15] #Выведем первые 5 строк и убедимся, что масштабированные данные были успешно добавлены в набор
     data.head()
```

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target	age_scaled	sex_scaled	cp_scaled	trestbps_scaled	chol_scaled	fbs_scaled	restecg_scaled	thalach_scaled	oldpeak_scaled	slope_scaled	ca_scaled	thal_scaled	target_scaled
0	63	1	3	145	233	1	0	150	0	2.3	0	0	1	1	0.708333	1.0	1.000000	0.481132	0.244292	1.0	0.0	0.603053	0.370968	0.0	0.0	0.333333	1.0
1	37	1	2	130	250	0	1	187	0	3.5	0	0	2	1	0.166667	1.0	0.666667	0.339623	0.283105	0.0	0.5	0.885496	0.564516	0.0	0.0	0.666667	1.0
2	41	0	1	130	204	0	0	172	0	1.4	2	0	2	1	0.250000	0.0	0.333333	0.339623	0.178082	0.0	0.0	0.770992	0.225806	1.0	0.0	0.666667	1.0
3	56	1	1	120	236	0	1	178	0	0.8	2	0	2	1	0.562500	1.0	0.333333	0.245283	0.251142	0.0	0.5	0.816794	0.129032	1.0	0.0	0.666667	1.0
4	57	0	0	120	354	0	1	163	1	0.6	2	0	2	1	0.583333	0.0	0.000000	0.245283	0.520548	0.0	0.5	0.702290	0.096774	1.0	0.0	0.666667	1.0

```
[16] #Выведем последние 5 строк
     data.tail()
```

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target	age_scaled	sex_scaled	cp_scaled	trestbps_scaled	chol_scaled	fbs_scaled	restecg_scaled	thalach_scaled	oldpeak_scaled	slope_scaled	ca_scaled	thal_scaled	target_scaled
298	57	0	0	140	241	0	1	123	1	0.2	1	0	3	0	0.583333	0.0	0.000000	0.433962	0.262557	0.0	0.5	0.396947	0.032258	0.5	0.00	1.000000	0.0
299	45	1	3	110	264	0	1	132	0	1.2	1	0	3	0	0.333333	1.0	1.000000	0.150943	0.315068	0.0	0.5	0.465649	0.193548	0.5	0.00	1.000000	0.0
300	68	1	0	144	193	1	1	141	0	3.4	1	2	3	0	0.812500	1.0	0.000000	0.471698	0.152968	1.0	0.5	0.534351	0.548387	0.5	0.50	1.000000	0.0
301	57	1	0	130	131	0	1	115	1	1.2	1	1	3	0	0.583333	1.0	0.000000	0.339623	0.011416	0.0	0.5	0.335878	0.193548	0.5	0.25	1.000000	0.0
302	57	0	1	130	236	0	0	174	0	0.0	1	1	2	0	0.583333	0.0	0.333333	0.339623	0.251142	0.0	0.0	0.786260	0.000000	0.5	0.25	0.666667	0.0

```
[17] # Убедимся, что масштабирование не повлияло на распределение данных
     for col in scale_cols:
         col_scaled = col + '_scaled'

         fig, ax = plt.subplots(1, 2, figsize=(8,3))
         ax[0].hist(data[col], 50)
         ax[1].hist(data[col_scaled], 50)
         ax[0].title.set_text(col)
         ax[1].title.set_text(col_scaled)
         plt.show()
```

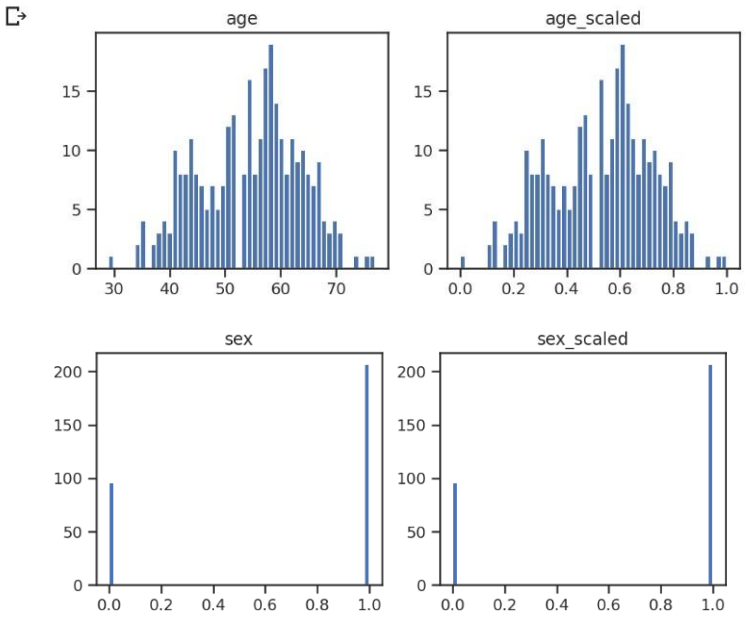

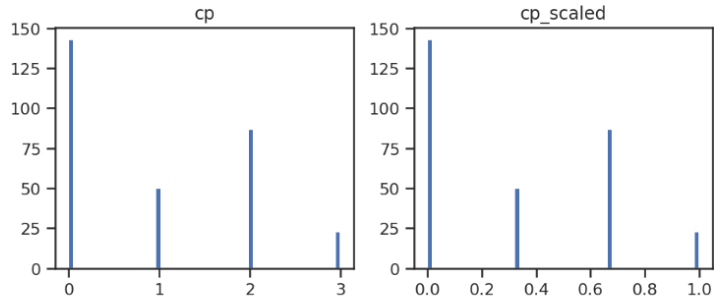
cp
cp_scaled

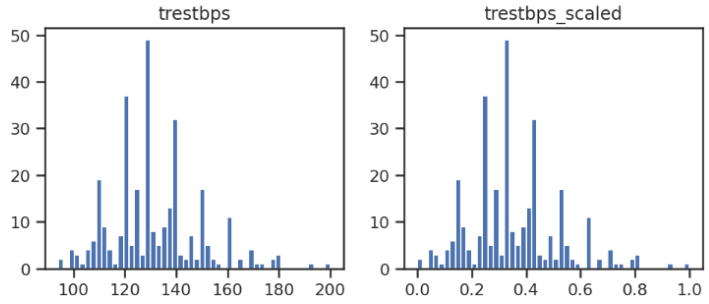
trestbps
trestbps_scaled

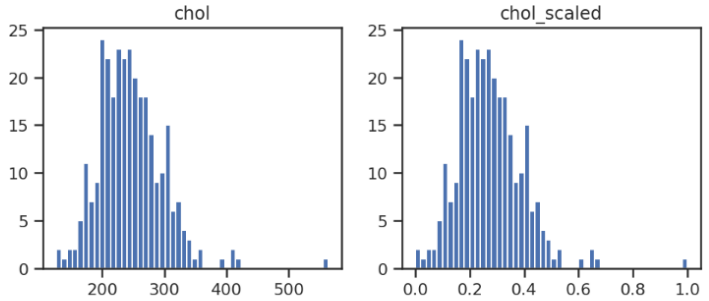
chol
chol_scaled

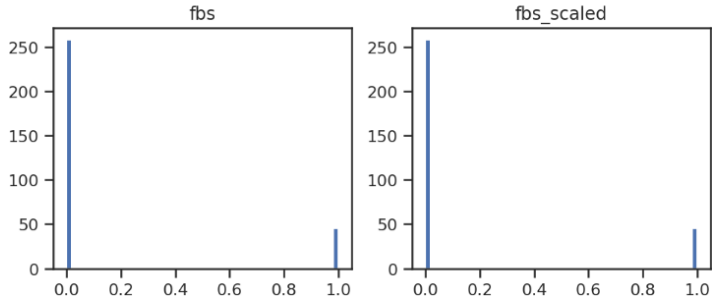
fbs
fbs_scaled

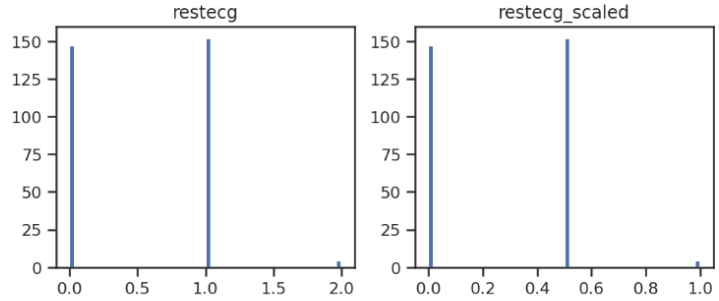
restecg
restecg_scaled

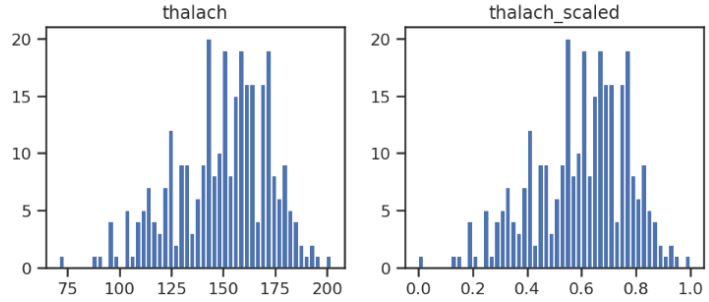
thalach
thalach_scaled

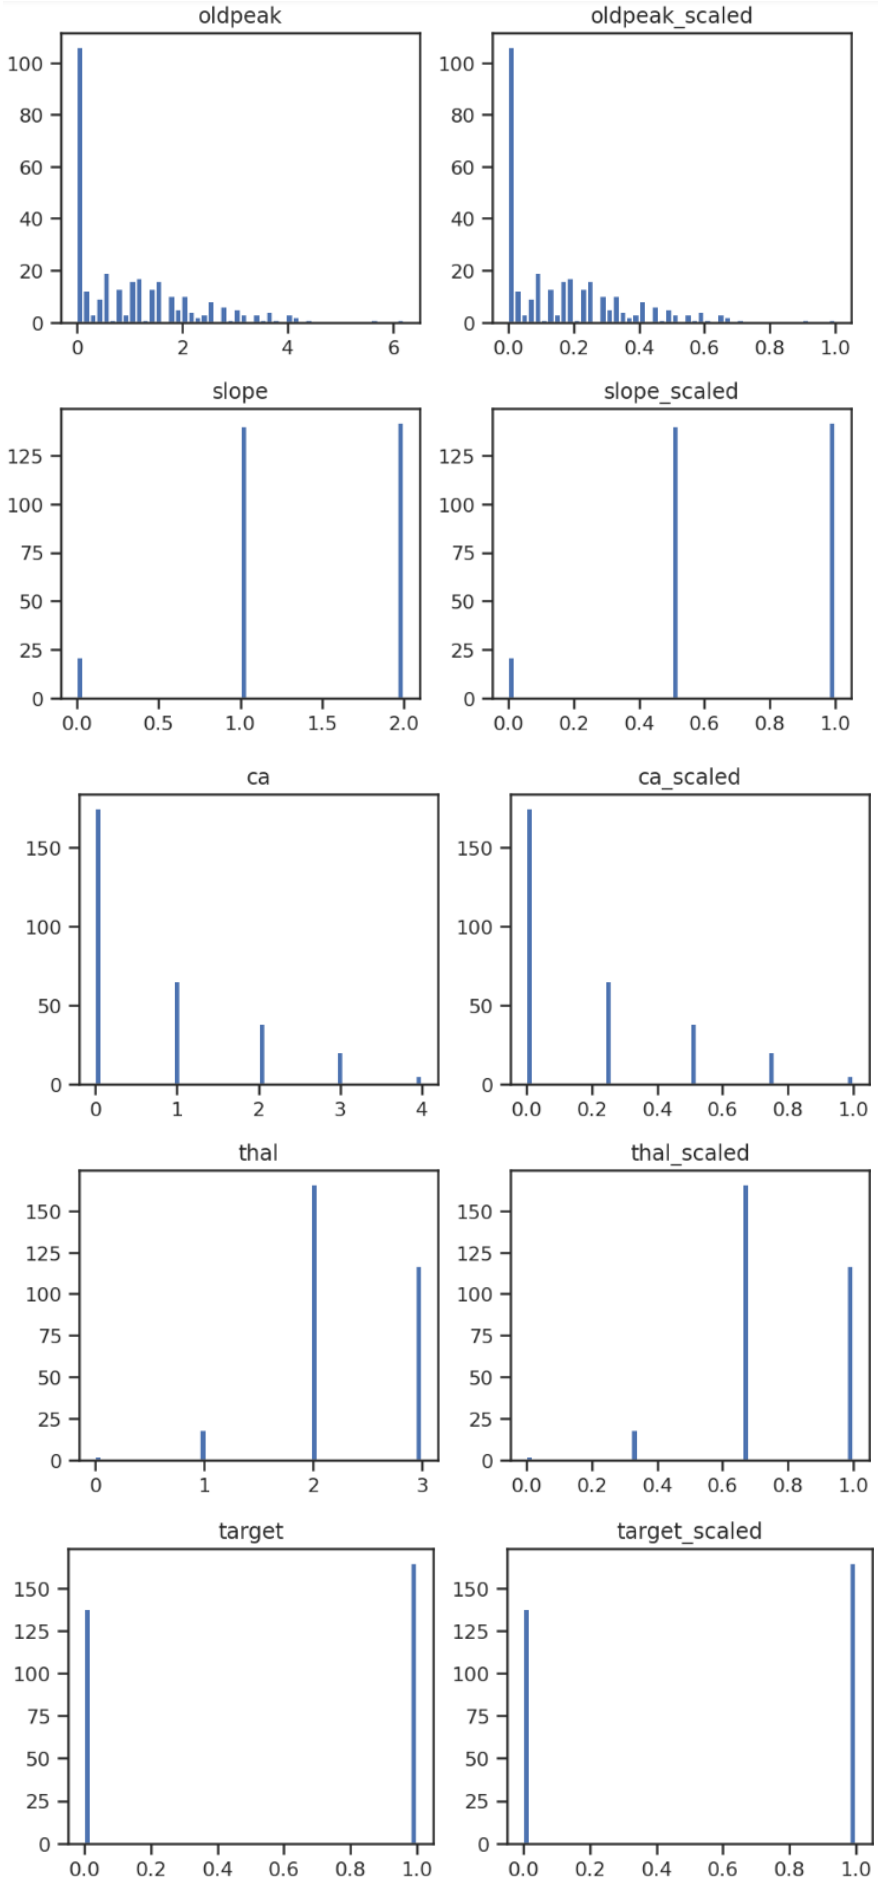
oldpeak
oldpeak_scaled
slope
slope_scaled
ca
ca_scaled
thal
thal_scaled
target
target_scaled

2.4. Проведение корреляционного анализа данных. Формирование промежуточных выводов о возможности построения моделей машинного обучения. В зависимости от набора данных, порядок выполнения пунктов 2, 3, 4 может быть изменен.

```
[18] corr_cols_1 = scale_cols + ['exang']
     corr_cols_1
```

```
['age',
 'sex',
 'cp',
 'trestbps',
 'chol',
 'fbs',
 'restecg',
 'thalach',
 'oldpeak',
 'slope',
 'ca',
 'thal',
 'target',
 'exang']
```

```
[19] scale_cols_postfix = [x+'_scaled' for x in scale_cols]
     corr_cols_2 = scale_cols_postfix + ['exang']
     corr_cols_2
```

```
['age_scaled',
 'sex_scaled',
 'cp_scaled',
 'trestbps_scaled',
 'chol_scaled',
 'fbs_scaled',
 'restecg_scaled',
 'thalach_scaled',
 'oldpeak_scaled',
 'slope_scaled',
 'ca_scaled',
 'thal_scaled',
 'target_scaled',
 'exang']
```

```
[20] fig, ax = plt.subplots(figsize=(10,10))
     sns.heatmap(data[corr_cols_1].corr(), annot=True, fmt='.2f')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f382d6aeb38>
```

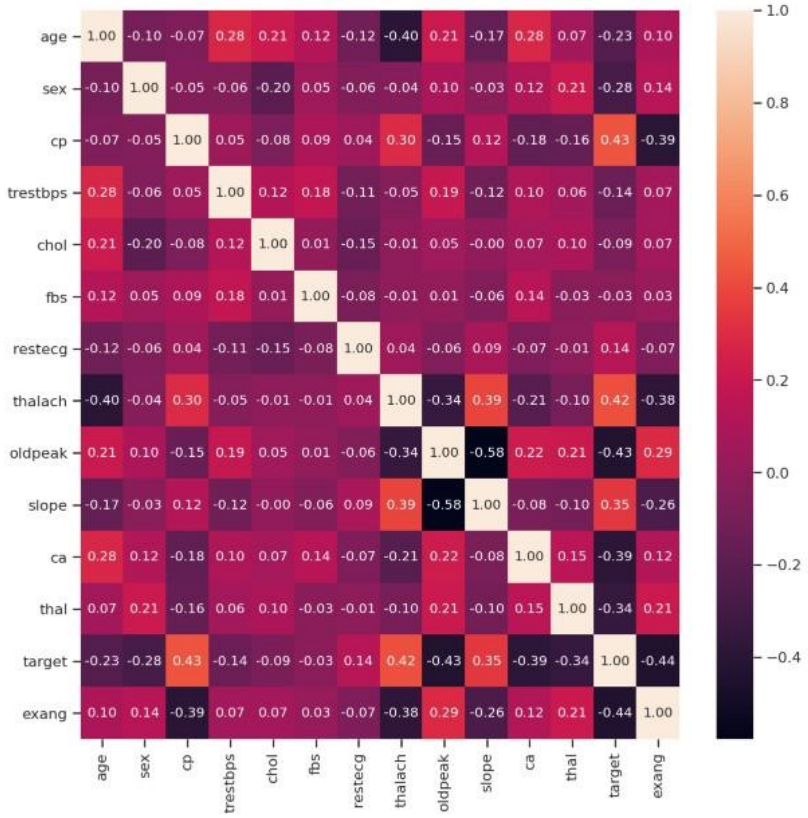


```
[21] fig, ax = plt.subplots(figsize=(10,10))
     sns.heatmap(data[corr_cols_2].corr(), annot=True, fmt='.2f')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f3830274e80>
```

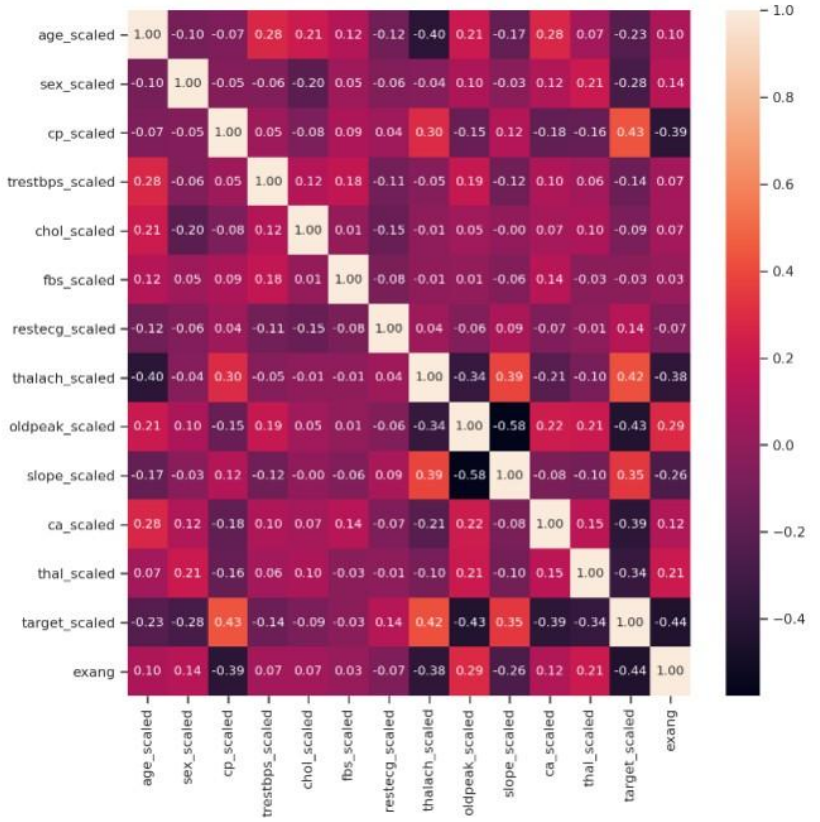

На основе корреляционной матрицы можно сделать следующие выводы:

- Корреляционные матрицы для исходных и масштабированных данных совпадают;
- Колонку trestbps, fbs, chol можно не включать, так как имеют очень слабую корреляцию с целевым признаком;
- Видно, что в данном наборе данных небольшие по модулю значения коэффициентов корреляции, это свидетельствуют о незначительной корреляции между исходными признаками и целевым признаком, но некоторая зависимость все равно имеется, поэтому на основании корреляционной матрицы можно сделать вывод о том, что данные позволяют построить модель машинного обучения.

2.5. Выбор метрик для последующей оценки качества моделей. Необходимо выбрать не менее трех метрик и обосновать выбор.

- Метрика accuracy — показывает отношения правильных предсказаний моделью ко всем

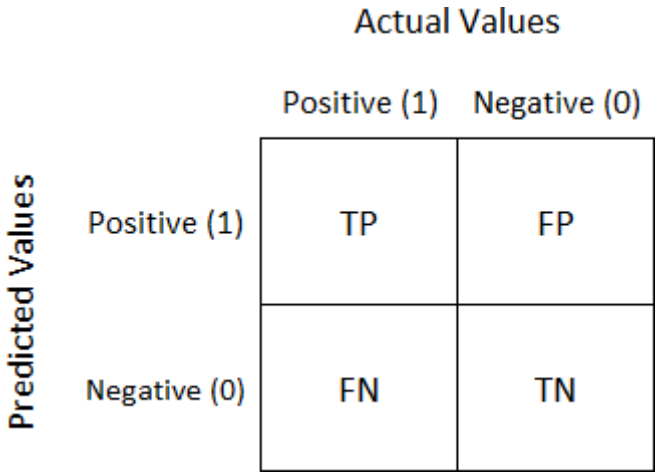

- Метрика precision — это отношение tp / (tp + fp). Доля верно предсказанных классификатором положительных объектов, из всех объектов, которые классификатор верно или неверно определил как положительные;

- Метрика recall — это отношение tp / (tp + fn). Доля верно предсказанных классификатором положительных объектов, из всех действительно положительных объектов;

- Метрика ROC AUC. Основана на вычислении следующих характеристик:
  - tp / (tp + fn) - откладывается по оси ординат. Совпадает с recall;
  - fp / (fp + tn) - откладывается по оси абсцисс. Показывает какую долю из объектов отрицательного класса алгоритм предсказал неверно. Идеальная ROC-кривая проходит через точки (0,0)-(0,1)-(1,1), то есть через верхний левый угол графика Чем сильнее отклоняется кривая от верхнего левого угла графика, тем хуже качество классификации. В качестве количественной метрики используется площадь под кривой - ROC AUC (Area Under the Receiver Operating Characteristic Curve). Чем ниже проходит кривая тем меньше ее площадь и тем хуже качество классификатора.

```
[22] # Отрисовка ROC-кривой
     def draw_roc_curve(y_true, y_score, pos_label=1, average='micro'):
         fpr, tpr, thresholds = roc_curve(y_true, y_score,
                                          pos_label=pos_label)
         roc_auc_value = roc_auc_score(y_true, y_score, average=average)
         plt.figure()
         lw = 2
         plt.plot(fpr, tpr, color='darkorange',
                  lw=lw, label='ROC curve (area = %0.2f)' % roc_auc_value)
         plt.plot([0, 1], [0, 1], color='navy', lw=lw, linestyle='--')
         plt.xlim([0.0, 1.0])
         plt.ylim([0.0, 1.05])
         plt.xlabel('False Positive Rate')
         plt.ylabel('True Positive Rate')
         plt.title('Receiver operating characteristic')
         plt.legend(loc="lower right")
         plt.show()
```

Разработаем класс, который позволит сохранять метрики качества построенных моделей и реализует визуализацию метрик качества:

```
[23] class MetricLogger:

        def __init__(self):
            self.df = pd.DataFrame(
                {'metric': pd.Series([], dtype='str'),
                'alg': pd.Series([], dtype='str'),
                'value': pd.Series([], dtype='float')})

        def add(self, metric, alg, value):
            """
            Добавление значения
            """
            # Удаление значения если оно уже было ранее добавлено
            self.df.drop(self.df[(self.df['metric']==metric)&(self.df['alg']==alg)].index, inplace = True)
            # Добавление нового значения
            temp = [{'metric':metric, 'alg':alg, 'value':value}]
            self.df = self.df.append(temp, ignore_index=True)

        def get_data_for_metric(self, metric, ascending=True):
            """
            Формирование данных с фильтром по метрике
            """
            temp_data = self.df[self.df['metric']==metric]
            temp_data_2 = temp_data.sort_values(by='value', ascending=ascending)
            return temp_data_2['alg'].values, temp_data_2['value'].values

        def plot(self, str_header, metric, ascending=True, figsize=(5, 5)):
            """
            Вывод графика
            """
            array_labels, array_metric = self.get_data_for_metric(metric, ascending)
            fig, ax1 = plt.subplots(figsize=figsize)
            pos = np.arange(len(array_metric))
            rects = ax1.barh(pos, array_metric,
                             align='center',
                             height=0.5,
                             tick_label=array_labels)
            ax1.set_title(str_header)
            for a,b in zip(pos, array_metric):
                plt.text(0.5, a-0.05, str(round(b,3)), color='white')
            plt.show()
```

2.6. Выбор наиболее подходящих моделей для решения задачи классификации или регрессии. Необходимо использовать не менее пяти моделей, две из которых должны быть ансамблевыми.

Для задачи классификации будем использовать следующие модели:

1. Метод ближайших соседей (KNN);
2. Машина опорных векторов (SVM);
3. Решающее дерево (Desicion Tree);
4. Случайный лес (Random Forest);
5. Градиентный бустинг (Gradient Boosting).

2.7. Формирование обучающей и тестовой выборок на основе исходного набора данных.

```
class_cols = ['age_scaled', 'sex_scaled', 'cp_scaled', 'restecg_scaled', 'thalach_scaled', 'oldpeak_scaled', 'slope_scaled', 'ca_scaled', 'thal_scaled', 'target_scaled']
```

```
[25] X = data[class_cols]
     y = data['exang']
     X.shape
```

```
(303, 10)
```

Разделим выборку на обучающую и тестовую

```
[26] # С использованием метода train_test_split разделим выборку на обучающую и тестовую
     X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25, random_state=1)
     print("X_train:", X_train.shape)
     print("X_test:", X_test.shape)
     print("y_train:", y_train.shape)
     print("y_test:", y_test.shape)
```

```
X_train: (227, 10)
X_test: (76, 10)
y_train: (227,)
y_test: (76,)
```

2.8. Построение базового решения (baseline) для выбранных моделей без подбора гиперпараметров. Производится обучение моделей на основе обучающей выборки и оценка качества моделей на основе тестовой выборки.

```
[27] # Модели
     models = {'KNN_3':KNeighborsClassifier(n_neighbors=3),
               'SVC':SVC(),
               'Tree':DecisionTreeClassifier(),
               'RF':RandomForestClassifier(),
               'GB':GradientBoostingClassifier()}
```

```
[28] # Сохранение метрик
     metricLogger = MetricLogger()
```

```
[29] def test_model(model_name, model, metricLogger):
         model.fit(X_train, y_train)
         y_pred = model.predict(X_test)

         accuracy = accuracy_score(y_test, y_pred)
         roc_auc = roc_auc_score(y_test, y_pred)
         precision = precision_score(y_test, y_pred)
         recall = recall_score(y_test, y_pred)
```

```
        metricLogger.add('precision', model_name, precision)
        metricLogger.add('recall', model_name, recall)
        metricLogger.add('accuracy', model_name, accuracy)
        metricLogger.add('roc_auc', model_name, roc_auc)

        print('****************************************************')
        print(model)
        print('****************************************************')
        draw_roc_curve(y_test, y_pred)

        plot_confusion_matrix(model, X_test, y_test,
                              display_labels=['0','1'],
                              cmap=plt.cm.Blues, normalize='true')
        plt.show()
```

```
[30] for model_name, model in models.items():
         test_model(model_name, model, metricLogger)
```

```
****************************************************
KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski',
                     metric_params=None, n_jobs=None, n_neighbors=3, p=2,
                     weights='uniform')
****************************************************
```

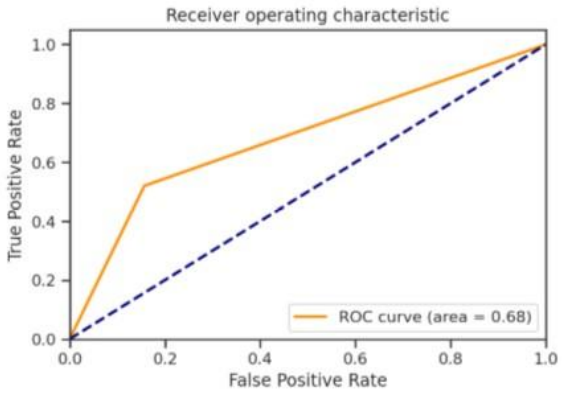

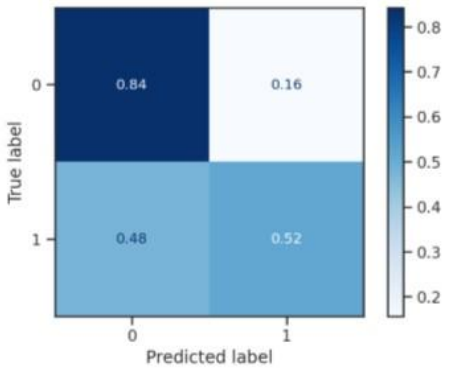


```
****************************************************
SVC(C=1.0, break_ties=False, cache_size=200, class_weight=None, coef0=0.0,
    decision_function_shape='ovr', degree=3, gamma='scale', kernel='rbf',
    max_iter=-1, probability=False, random_state=None, shrinking=True,
    tol=0.001, verbose=False)
****************************************************
```

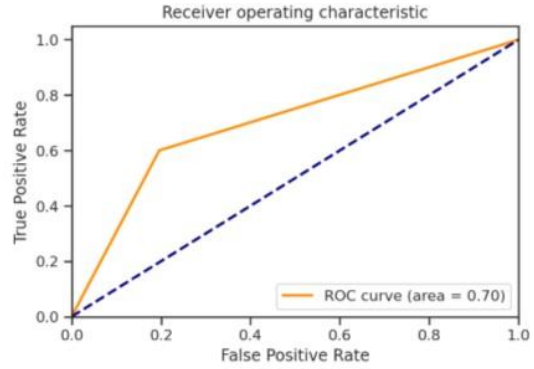

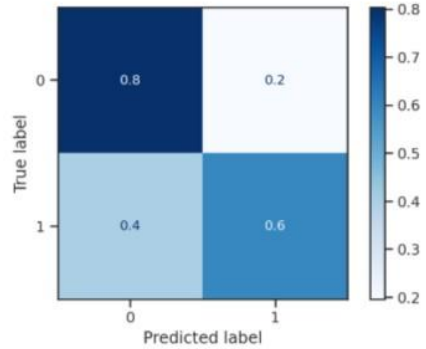


```
**********************************************************
DecisionTreeClassifier(ccp_alpha=0.0, class_weight=None, criterion='gini',
                       max_depth=None, max_features=None, max_leaf_nodes=None,
                       min_impurity_decrease=0.0, min_impurity_split=None,
                       min_samples_leaf=1, min_samples_split=2,
                       min_weight_fraction_leaf=0.0, presort='deprecated',
                       random_state=None, splitter='best')
**********************************************************
```

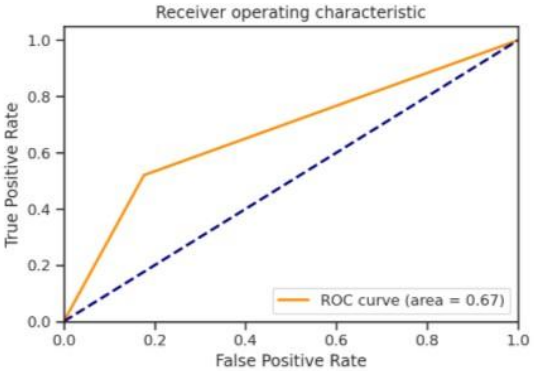

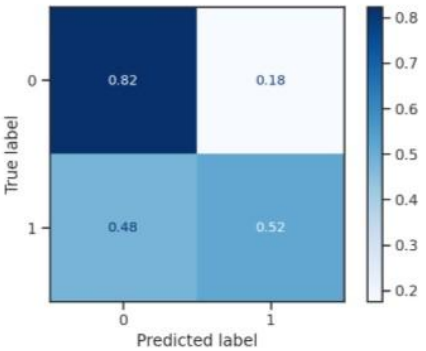


```
**********************************************************
RandomForestClassifier(bootstrap=True, ccp_alpha=0.0, class_weight=None,
                       criterion='gini', max_depth=None, max_features='auto',
                       max_leaf_nodes=None, max_samples=None,
                       min_impurity_decrease=0.0, min_impurity_split=None,
                       min_samples_leaf=1, min_samples_split=2,
                       min_weight_fraction_leaf=0.0, n_estimators=100,
                       n_jobs=None, oob_score=False, random_state=None,
                       verbose=0, warm_start=False)
**********************************************************
```

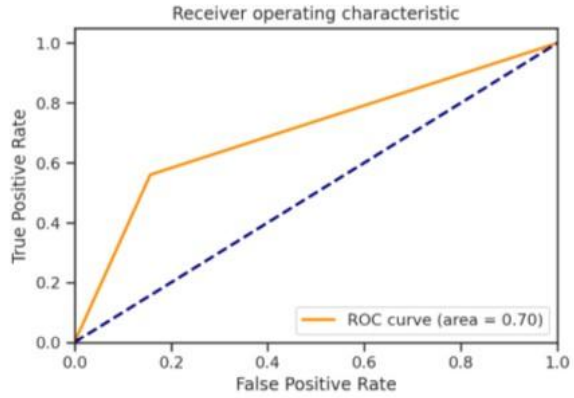

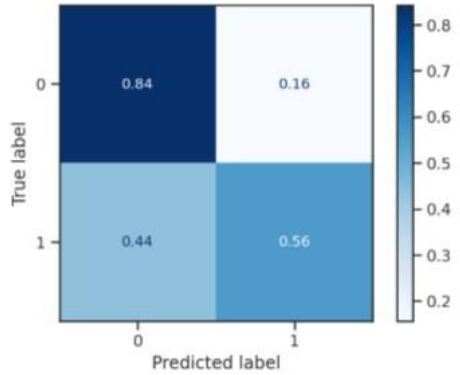

****

```
GradientBoostingClassifier(ccp_alpha=0.0, criterion='friedman_mse', init=None,
                           learning_rate=0.1, loss='deviance', max_depth=3,
                           max_features=None, max_leaf_nodes=None,
                           min_impurity_decrease=0.0, min_impurity_split=None,
                           min_samples_leaf=1, min_samples_split=2,
                           min_weight_fraction_leaf=0.0, n_estimators=100,
                           n_iter_no_change=None, presort='deprecated',
                           random_state=None, subsample=1.0, tol=0.0001,
                           validation_fraction=0.1, verbose=0,
                           warm_start=False)
```

****

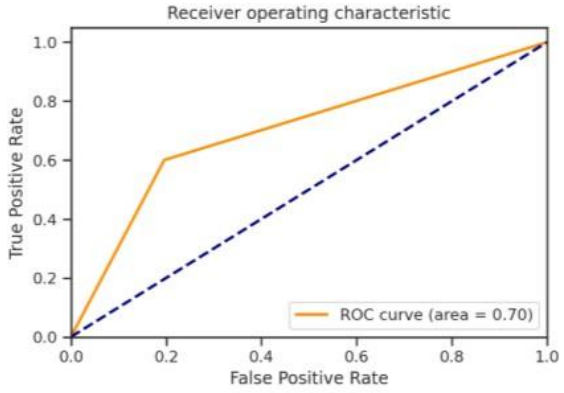

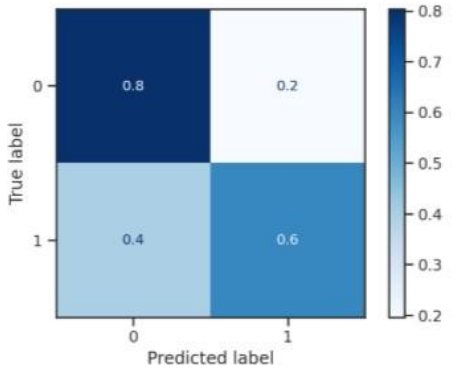

2.9. Подбор гиперпараметров для выбранных моделей. Рекомендуется использовать методы кросс-валидации. В зависимости от используемой библиотеки можно применять функцию GridSearchCV, использовать перебор параметров в цикле, или использовать другие методы.

```
[31] n_range = np.array(range(0,30,1))
     tuned_parameters = [{'n_neighbors': n_range}]
     tuned_parameters
```

```
[{'n_neighbors': array([ 0,  1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13, 14, 15, 16,
        17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29])}]
```

```
[32] %%time
     clf_gs = GridSearchCV(KNeighborsClassifier(), tuned_parameters, cv=5, scoring='accuracy', n_jobs = -1)
     clf_gs.fit(X, y)
```

```
CPU times: user 227 ms, sys: 35.4 ms, total: 263 ms
Wall time: 2.13 s
```

```
[33] # Лучшая модель
     clf_gs.best_estimator_
```

```
KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski',
                     metric_params=None, n_jobs=None, n_neighbors=20, p=2,
                     weights='uniform')
```

```
[34] # Лучшее значение параметров
     clf_gs.best_params_
```

```
{'n_neighbors': 20}
```

```
[35] # Изменение качества на тестовой выборке в зависимости от K-соседей
     plt.plot(n_range, clf_gs.cv_results_['mean_test_score'])
```

```
[<matplotlib.lines.Line2D at 0x7fc60c44e898>]
```

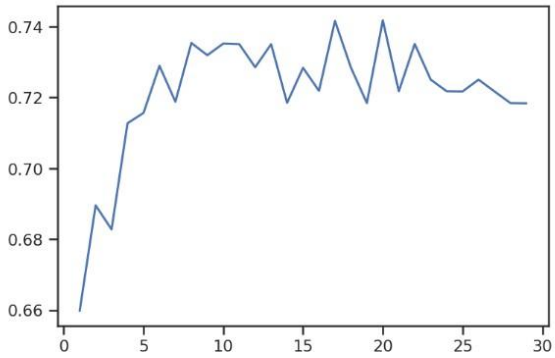

2.10. Повторение пункта 8 для найденных оптимальных значений гиперпараметров. Сравнение качества полученных моделей с качеством baseline-моделей.

```
[36] test_model('KNN_5', KNeighborsClassifier(n_neighbors=5), metricLogger)
```

```
**********************************************************
KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski',
                     metric_params=None, n_jobs=None, n_neighbors=5, p=2,
                     weights='uniform')
**********************************************************
```

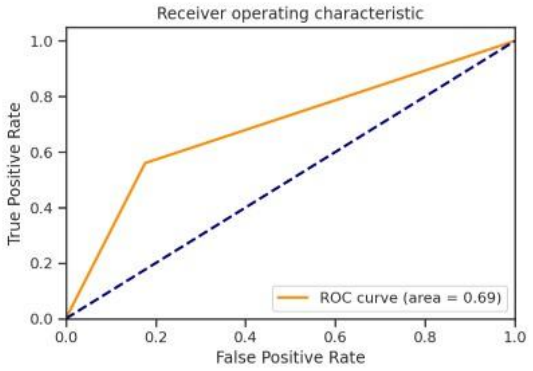

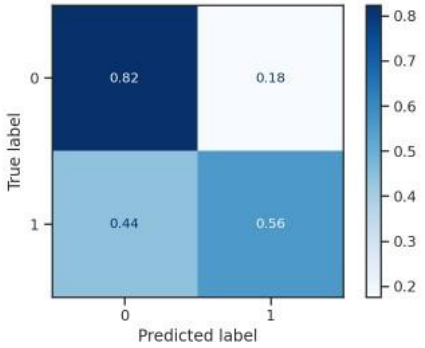

2.11. Формирование выводов о качестве построенных моделей на основе выбранных метрик. Результаты сравнения качества рекомендуется отобразить в виде графиков и сделать выводы в форме текстового описания. Рекомендуется построение графиков обучения и валидации, влияния значений гиперпарметров на качество моделей и т.д.

```
[37] # Метрики качества модели
     metrics = metricLogger.df['metric'].unique()
     metrics
```

```
array(['precision', 'recall', 'accuracy', 'roc_auc'], dtype=object)
```

```
[38] # Построим графики метрик качества модели
     for metric in metrics:
         metricLogger.plot('Метрика: ' + metric, metric, figsize=(7, 6))
```

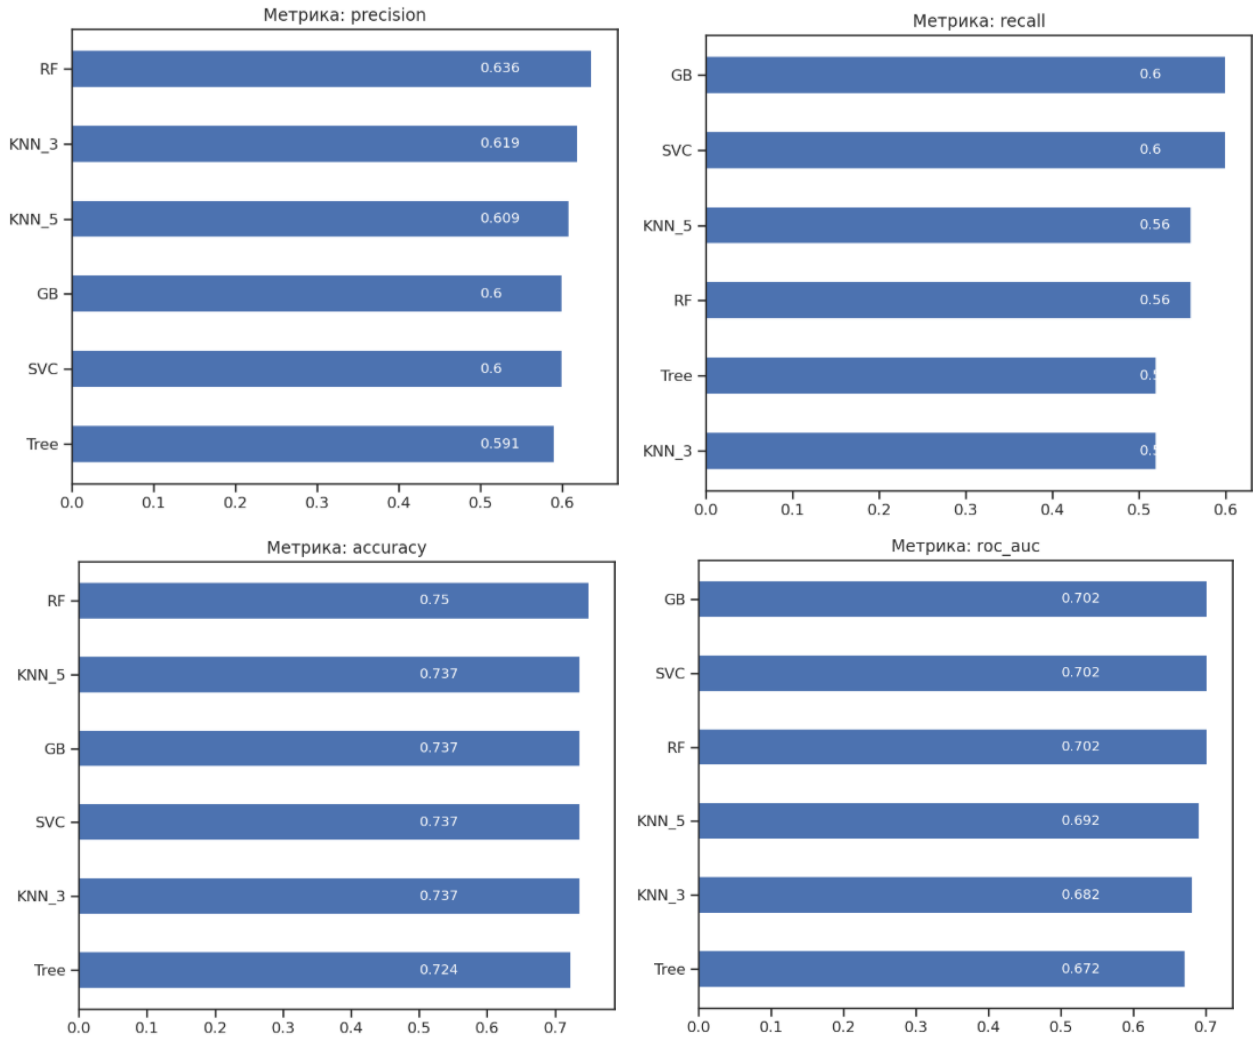

Вывод: на основании трех метрик из четырех используемых, лучшей оказалась модель SVC - метод опорных векторов. Случайный лес в четвертой метрике precision совсем немного выиграл у SVM.

3. ЗАКЛЮЧЕНИЕ

В данном курсовом проекте мы выполнили типовую задачу машинного обучения. Провели анализ данных, провели некоторые операции с датасетом, подобрали модели, а также подобрали наиболее подходящие гиперпараметры.

В нашем случае классификатор на основе метода опорных векторов показал лучшие результаты в 75% метрик. В последней метрике немного уступил классификатору на основе случайного леса.

В данном проекте были закреплены все знания, полученные в данном курсе.

Машинное обучение очень актуально в современном мире, оно используется практически во многих сферах. Программист должен подбирать подходящие технологии машинного обучения для достижения наилучших результатов.

4. ЛИТЕРАТУРА

1. Лекции 6-го семестра 2020 года по дисциплине «Технологии машинного обучения»
2. https://scikit-learn.org/stable/index.html
3. https://www.kaggle.com/ronitf/heart-disease-uci Электронный ресурс. Дата обращения 01.06.2020